

ACTIVIDAD 3 - DESCRIPCIÓN DE LOS DATOS

Proyecto: Modelo supervisado para predecir retrasos en un sistema de transporte.

1. Fuente de los datos

El proyecto de transporte desarrollado en las actividades anteriores es una simulación académica y no cuenta con un historial real de viajes. Por esta razón se construyó un dataset simulado de 72 registros. Cada fila representa un viaje y contiene variables que pueden influir en la ocurrencia de un retraso.

Los datos se utilizan únicamente con fines académicos para entrenar y probar un modelo de aprendizaje supervisado basado en un árbol de decisión.

2. Variables

Variable	Tipo	Descripción
id_viaje	Entero	Identificador consecutivo del viaje.
pasajeros	Entero	Cantidad de pasajeros del recorrido.
numero_paradas	Entero	Número de paradas realizadas.
transbordos	Entero	Cantidad de cambios o transbordos.
tiempo_estimado	Entero	Tiempo estimado del recorrido en minutos.
hora_pico	Binaria	1 = hora pico; 0 = fuera de hora pico.
retraso	Clase	Variable objetivo: Si = retraso; No = sin retraso.

3. Variable objetivo

La variable **retraso** es la etiqueta que el modelo debe aprender a predecir. El problema corresponde a una clasificación binaria: **Si** o **No**.

4. Relación con el proyecto anterior

La Actividad 2 buscaba una ruta entre estaciones mediante reglas y búsqueda heurística. En esta actividad se añade aprendizaje supervisado para responder una pregunta diferente: dados los datos de un recorrido, ¿es probable que el viaje presente retraso?

5. Preparación

El conjunto se divide de forma estratificada en aproximadamente 70 % para entrenamiento y 30 % para prueba. La implementación usa Python estándar, entropía y ganancia de información para construir el árbol.