

ACTIVIDAD 3 - DESCRIPCIÓN DE LOS DATOS

Proyecto: Modelo supervisado para predecir retrasos en un sistema de transporte.

1. Fuente de los datos

El proyecto de transporte que se desarrolló en las actividades anteriores es una simulación académica y no tiene un historial real de viajes. Por eso se creó un dataset simulado con 72 registros. Cada fila representa un viaje y tiene variables que pueden influir en un retraso. Los datos se usan solo con fines académicos para entrenar y probar un modelo de aprendizaje supervisado basado en un árbol de decisión.

2. Variables

Variable	Tipo	Descripción
id_viaje	Entero	Identificador consecutivo del viaje.
pasajeros	Entero	Cantidad de pasajeros del recorrido.
numero_paradas	Entero	Número de paradas realizadas.
transbordos	Entero	Cantidad de cambios o transbordos.
tiempo_estimado	Entero	Tiempo estimado del recorrido en minutos.
hora_pico	Binaria	1 = hora pico; 0 = fuera de hora pico.
retraso	Clase	Variable objetivo: Si = retraso; No = sin retraso.

3. Variable objetivo

La variable **retraso** es la etiqueta que el modelo debe aprender a predecir. El problema corresponde a una clasificación binaria: **Si** o **No**.

4. Relación con el proyecto anterior

La Actividad 2 se centró en encontrar una ruta entre estaciones usando reglas y búsqueda heurística. En esta actividad, se agrega aprendizaje supervisado para responder una nueva pregunta: dado el conjunto de datos de un recorrido, ¿es probable que el viaje tenga retraso?

5. Preparación

El conjunto se divide de forma estratificada en aproximadamente 70 % para entrenamiento y 30 % para prueba. La implementación usa Python estándar, entropía y ganancia de información para construir el árbol.